

大模型微调实现机械制图规范XML提取的方案

问题分析

在这个项目中，我们需要将**长篇幅的技术规范文档**（由OCR识别输出的JSON格式文本）转换为**特定格式的XML规则文件**。每个技术规范文档（约18份）内容复杂且篇幅较长，直接输入大型语言模型会超出其上下文长度限制。此外，训练阶段和推理阶段都受限于模型的上下文窗口，我们无法一次性将完整文档输入模型。主要挑战包括：

- **文档内容长，模型上下文有限**：文本动辄上万字，235B参数模型（如 Qwen3）可能只有数千字符的上下文窗口，直接输入完整文档不可行。
- **内容语义连续性**：若强行按固定长度或页码分块，可能打断句子或段落，使模型难以理解上下文，导致规则提取不准确。
- **训练数据有限**：只有18个文档样本，直接微调大模型易过拟合，需要 careful 策略提取有效信息。
- **输出结构严格**：目标XML格式要求明确，每条规则需正确嵌入在 `<Rule>` 等标签中，格式必须正确闭合，对模型输出的格式准确性要求高。

针对以上问题，我们需要设计一种**分阶段、层次化**的方案，在保证语义完整的情况下，将长文档划分处理，并微调模型生成所需的XML结构。

方案概述

我们提出一个“**预处理 + 分段抽取 + 分阶段微调 + 分步生成**”的解决方案，具体分为以下几个步骤：

1. **数据预处理**：清洗和初步过滤OCR文本，去除无关内容，依据文档结构和语义将长文本划分为若干**语义片段**。
2. **关键内容提取**：利用规则或小模型，从每个片段中**筛选出规范要求的句子**（含有“必须”、“应当”、“不得”等关键词的句子），突出关键信息。
3. **语义分块**：根据文档的章节结构和内容主题，将提取的句子和相邻上下文组合成**较小的语义单元块**。每个单元对应一个或多个相关的规则条目。
4. **训练数据构建**：为每个语义单元块准备对应的**目标XML片段**（人工或借助辅助模型生成正确的XML格式输出），形成模型微调所需的输入-输出对。
5. **模型微调**：采用LoRA/QLoRA等参数高效微调技术，在本地大模型上进行**监督微调（SFT）**，让模型学习从文本片段生成XML规则片段的能力。
6. **分步推理与组装**：在推理阶段，对长文档采用与训练一致的分块策略，**逐块输入模型生成部分XML**，最终将所有部分组合成完整的XML文件。

下面我们对各步骤进行详细说明和策略阐述。

数据预处理

1. **清洗过滤**：首先对OCR导出的JSON进行基础清洗，过滤掉与规则无关的内容，包括：- **前言、引言**等非规范性描述（如标准的前言、致谢、历史修订说明等），因为这些部分不包含具体检查规则。- **参考标准列表**（引用标准编号等），它们不直接产生规则要求。- **纯说明性段落**：例如定义章节（术语解释）通常不直接转化为检查规则，可暂时忽略。- **冗余信息**：OCR噪音、页眉页脚、空白页提示等无关文本。

通过上述过滤，保留文档中**真正描述技术要求的正文部分**，减少模型处理的无效文本量。

2. 基于结构的分段：利用文档内在的结构（例如章/节标题、编号）进行初步分段： - 按**章/节**划分：如文档按“1 范围”“2 引用标准”“3 定义”“4 要求…”这样的层级结构，我们可以利用 JSON 中的 `text_level` 属性或标题格式，将文档内容按一级或二级标题划分段落。【用户提供的JSON示例显示 `text_level` 可帮助识别标题等级】这样每个段落对应文档的一个主题块，便于后续处理。 - 按**页面**辅助：如果OCR按页输出，我们可用页面索引（`page_idx`）辅助检查，但不机械地逐页切分。尽量在**自然段落或章节边界**处分段，避免跨页连续的段落被截断。

通过结构分段，我们得到每个文档的多个**章节文本**。这些章节通常围绕特定主题，例如示例文档中可能有“设计牙型要求”、“基本尺寸公差”、“标记方法”等章节。

3. 控制片段长度：为了适应模型上下文，每个分段后的文本长度应**控制在模型上下文大小以内**。例如如果模型上下文是2048 tokens，预留一部分给指令和格式，占比如100-200 tokens，那么文本片段尽量不超过1800 tokens左右。 - 若某章节内容仍偏长，可以**进一步子分段**：按自然段落或小节拆分，或以**语义断点**（如句号、分号等句末）进行切分。同时确保不打破**重要句子或表格、公式**的连续性，可在句子边界或段落边界分割。 - 如果必须拆分长段，也可以采用**重叠滑窗**策略：后一片段的开头重复前一片段末尾几句话，以提供上下文衔接。这样模型在处理后续块时能参考前文，减轻上下文丢失的问题。

经过以上处理，我们获得了**若干语义片段**，每个片段对应文档中相对独立的一部分，为后续步骤奠定基础。

关键内容提取

在每个语义片段中，我们需要找出**与规则检查直接相关的句子**。技术标准中的规则通常以**要求式语言**表述。我们可以采用**关键词筛选结合规则模板**的方法：

- **关键词筛查：**定义一组指示规范要求的关键词或句型，例如：
 - 中文中的“**必须**”、“**应/应当**”、“**不得**”、“**禁止**”、“**要求**”、“**需要**”等；
 - 如果有英文内容则关注“**shall**”、“**should**”、“**must**”、“**shall not**”、“**allowed**”等。扫描片段文本，提取包含这些关键词的句子。通常这些句子直接或间接描述了**强制性要求或约束条件**。
- **正则与模式匹配：**利用正则表达式寻找常见格式的规定句，比如“…应为…”，“…不得超过…”，“…应符合…规定”等。这可以自动抓取许多关键要求语句。
- **结构线索：**标准中**列表条款**（如条目用数字或破折号列出）往往每条都是一个要求。OCR文本中可能用换行和数字表示列表，识别例如“1) …”，“2) …”或“a. …, b. …”等模式，可将每个列表项视为一条规则语句。
- **表格和公式：**有时规范要求以表格形式给出（例如允许值范围）或公式定义（如尺寸计算公式）。对于表格数据，要提取其中**限制值或指定值**，如公差表要求尺寸范围。对于公式，需判断是否有**规定的变量意义或必须满足的关系**。若仅是参考计算公式，可不作为检查规则；若是**必须按该公式计算**，则提取这一要求。

经过关键词和模式筛选，我们从每个片段提炼出**候选规则句集合**。然而仅凭关键词可能会有冗余或误判，因此我们可以进一步**人工或模型复核**：

- **人工过筛：**人工快速浏览筛选出的句子，剔除那些不是规范要求的句子（例如叙述背景的句子包含“应”字但非要求）。
- **辅助小模型：**用一个小型的本地模型或语言工具，总结片段中“哪些是要求或规定”。例如，提示一个基础模型：“从以下文本提取所有要求性的语句”。这样自动化获取重要语句，提高效率。

输出关键句：这一步的结果是在每个语义片段里得到若干关键要求句。为了保留上下文，我们也记录每条关键句的**邻近内容**（上下几句），以便模型理解语境。如“标记符号应以‘.’表示”这句规则，前文可能解释背景，后文给出例子，都可以一并提供给模型参考生成解释或示例值。

语义分块（聚类与归类）

有了关键句之后，我们需要组织它们，使每个训练输入对应具体的**规则组或条目**。这里采用**语义分块**的策略，确保每块内容围绕**单一主题或检查项**：

- **按章节主题归类**：通常，一个章节（或小节）围绕一个大的方面，其内部可能有多个细节要求。例如“6 标记”章节可能包含几个要求：“比例符号表示方法”、“视图中不同方向允许不同比例”等。我们可以按小节标题或段落主题，将关键句归并。在JSON中已有 `text_level` 和标题文本，可利用这些**标题**作为规则类别。例如检测到“小节‘比例选择’”和“小节‘标注方法’”，则分别归类相关句子。
- **语义相似度聚类**：如果文档结构不明显或主题交叉，可以使用**向量嵌入**技术：对每条关键句生成 Embedding，将相似语义的句子进行聚类。比如句子都涉及“比例值”的，就聚为一组（对应比例选择规则）；涉及“符号表示”的一组（对应标注方法规则）；涉及“公差数值”的一组等。这样自动按意义分组，有助于发现潜在的规则项。
- **组合上下文**：对每组句子，我们取它们在原文中的**完整段落或邻接内容**作为最终语义单元的文本。例如，“比例选择”这一组，可能对应原文一个段落列出了可选比例值清单；我们保留整个清单内容作为输入文本，而不只是关键词句。这样模型有充足信息生成正确的规则Value列表（如“1:1, 2:1, …”）。
- **确保片段独立完整**：每个语义单元块应尽量**自包含**该规则所需的信息，避免跨单元依赖。例如“比例符号应以‘:’表示”这个要求，与“比例值范围”是相关但可独立的两项。我们划分成不同单元，各自包括其说明文字。这样模型生成XML时，每块只输出特定 `<RuleItem>`，不会混淆多个规则。

经过语义分块，我们将原始长文档的信息压缩为**若干个相对短小且主题集中的文本片段**，每个片段对应我们最终XML中的一个**Rule**或一个**RuleItem**（含多个Rule子项）。这大幅降低了模型输入长度，并保证了每次模型生成聚焦于特定规则，不受全文干扰。

训练数据构建

有了分块后的**输入片段**，我们需要为它们准备对应的**输出XML**，然后构造微调训练样本。关键步骤如下：

- **确定输出粒度**：根据分块情况，决定每个训练样本输出是完整的 `<RuleItem>` 段还是仅 `<Rule>` 条目。本方案倾向于**每个主题块生成一个完整的 `<RuleItem>`**，因为一个RuleItem往往对应文档一个小节（含若干具体规则参数）。例如，“比例选择”片段对应输出：

```
<RuleItem Name="比例选择" ...>
  <CheckConfig>
    <Rule Name="..." Value="1:1, 2:1, 5:1, 1:2, 1:5, 1:10"/>
  </CheckConfig>
</RuleItem>
```

内部可能有多个 `<Rule>` 子元素。如果某主题特别简单也可能直接对应一个 `<Rule>`，但为了统一，我们仍以RuleItem为单位，包含至少一个Rule子节点。

- **手工编写示例输出**：由于模型尚未学会生成XML，我们需要提供**示范输出**。可以：
- 参考标准规范和需求，**人工撰写**每个输入片段对应的正确XML片段。尤其是Name、Description、Value等字段要从原文提炼准确。人工保证XML结构和语义正确。
- 若人工工作量大，可借助外部大模型（如GPT-4）**协助生成初稿**，然后由人工校对修正，确保符合我们XML格式要求。这18个文档即使每个有数个RuleItem，总量也不算太高，人工校对是可行的。
- **形成训练对**：将每个语义片段文本作为输入 `X`，对应的XML片段作为目标输出 `Y`，组成监督微调样本。为了帮助模型了解任务，可以在输入前增加一定的**提示指令**，例如：

输入：{片段文本}
任务：请根据以上标准内容，提炼规则要求，输出符合规范检查的XML片段。
输出：
<RuleItem ...> ... </RuleItem>

这样模型在训练中学习：给定标准文字，需要输出XML格式的规则定义。**注意**保持提示的一致性，在推理时也用相同风格提示，引导模型产出所需格式。

- **样本数量**：如果18个文档，每个文档经分块可能产生数个训练样本。比如每份标准有5-10条规则，那么总共训练样本数或许在100条左右。样本虽不多，但每条样本内容相对集中明确，有助于模型学习格式和关键内容对齐。

在这个过程中，还要**定义好XML结构约束**：

- `RuleItem` 的 Name、Description 等字段如何取值：通常Name来自小节标题或主题，如“比例选择”、“标注方法”。Description可来自标准原文对该规则的解释。
- `Rule` 元素的 Name 和 Value：Name可以是规则检查点的代号或名称，如示例里的“xxx”、“xx”，Value则是具体允许的取值或符号等。
- 有些检查项可能需要多个 `Rule`元素（如分别列出若干参数的允许值），则确保在一个 `RuleItem` 的 `CheckConfig` 下都列出。

通过精心构造训练数据，我们让模型**明确示范**了从自然语言到XML规则的映射关系。

模型微调策略

针对我们的大模型（Qwen3 235B）和有限的训练数据，采用**高效微调策略**，以降低计算需求并避免过拟合：

- **LoRA 微调**：利用 LoRA（Low-Rank Adaptation）技术，锁定模型原有权重，只训练新增的适应层。这样大幅减少需更新的参数量，在两张 A6000（共96GB）上可微调一个数百亿参数模型。对于235B这样超大模型，可以选取 LoRA Rank 较小的配置，只训练 Q,K,V 投影等少量矩阵。
- **QLoRA 量化**：进一步地，可以对模型权重进行**4-bit量化**（如近期流行的 QLoRA 方法），将模型加载到较低精度以节省显存，同时进行 LoRA 微调调整量化权重。QLoRA 已成功用于65B参数模型在单卡48GB上微调，我们在双卡下对235B模型进行分层加载（可能切分为多个部分放两卡）也可以考虑。有了量化，显存占用降低，虽然235B仍然很大，但可以尝试分布式并行或 CPU+GPU 混合训练。
- **训练参数**：由于样本不多，采用**小批量（batch size）**和**低学习率策略**。比如 batch size 可以为1-2（每次一个样本），learning rate在1e-4量级甚至更低，避免过拟合。通过观察验证集（如果切出部分样本做验证）上XML输出格式的准确率来停止训练。
- **监督微调（SFT）**：微调过程实际上是一个监督学习，让模型模仿我们的示范输出。可以按照**指令微调**格式构造数据（如在输入前加“根据以上内容生成XML”这类说明）。因为最终我们希望模型根据提示完成任务，这种格式下训练能让模型更好地遵循指令行事。
- **多任务微调（可选）**：如果有条件，也可以加入少量相关格式转换数据扩充训练，使模型更通用。但在项目范围内，直接用这18个标准的规则提取任务进行微调已足够完成需求。

微调完成后，我们会得到一个**专门适应于机械制图规范抽取**的模型。它应该学到了如何从技术要求描述中提炼关键信息并组装成XML格式输出。

分步推理与结果组装

由于模型上下文限制，推理时仍需采用**分步生成**。整个推理流程如下：

1. **章节级生成**：按照和训练一致的策略，将待转换的文档先做预处理和语义分块。然后**逐块输入模型**：
2. 对每个片段，前面加上适当的提示语（例如：“下面根据标准文本生成规则XML：”），让模型生成对应的XML片段（通常一个 `<RuleItem>` 块）。

3. 例如，输入片段是关于比例选择的内容，则提示模型“提取比例选择规则”，模型输出 `<RuleItem Name="比例选择"...>...</RuleItem>` 这一段XML。
4. 逐一处理文档的每个语义片段，获取多段XML输出。
5. **结果检查**：对于模型给出的每段XML，可以编程地进行格式校验：
6. 检查XML标签是否完整闭合，字段是否齐全。
7. 如果模型偶尔遗漏了某个标签或属性，用简单规则或模板**纠正格式**（例如确保 `<CheckConfig>` 有关闭标签等）。由于训练样本教会了模型正确格式，这种错误预计较少见。
8. 内容方面，核对关键值是否合理。例如原文列出了6个比例值，模型输出也应有6个值，与原规范一致。对于明显不符之处，可能需要人工调整或再次提示模型修正。
9. **XML组合**：将所有输出的 `<RuleItem>` 片段插入到完整XML骨架中：
10. 事先准备好XML的固定开头 `<SpecificationCheck><CheckGroup Name="XXX检查" DocType="Standard">` 和结尾 `</CheckGroup></SpecificationCheck>`。
11. 将模型生成的若干 `<RuleItem>` 片段依次放入 `<CheckGroup>` 内部。顺序可以根据原文章节顺序排列，确保逻辑一致。
12. 组合后形成一个完整的XML文件即为该文档的规范规则提取结果。
13. **验证与测试**：对最终XML，可以使用标准的XML解析器验证格式正确无误。然后将其输入既有的规范检查软件，验证能否正确识别并检查对应的机械图纸要求。如果软件能够依据生成的XML正常工作（比如识别比例是否合规、公差范围是否正确），则证明我们的提取是成功的。
14. 由于项目以展示为主，可选取一两份生成的XML进行演示，证明模型输出能应用在实际检查流程中。
15. 若有少数不符合的软件预期之处，手动调整XML内容（这是可以接受的，因为微调模型结果本身就允许再编辑）。

值得注意的是，如果模型支持较长上下文或未来采用了扩展上下文的版本，我们也可以尝试**整合输入**减少步骤：- 例如，使用支持16K或32K上下文的模型（一些开源大模型的长上下文版本）直接输入整个文档，让其一次输出完整XML。这需要模型架构支持和足够算力。目前我们的资源有限，分段处理是更稳妥的方案。- 还有一种折中方案是**链式 prompting**：先提示模型列出该标准包含的规则项名称，然后根据列出的项逐项深入生成XML内容。这类似手动的链式推理，但需要模型准确识别出规则目录。在训练数据有限的情况下，这一步可能不够稳健，因而本方案采用我们更可控的预处理方式替代。

其他优化考虑

- **使用提示增强格式可靠性**：可以在提示中明确要求：“请严格按照XML格式输出，不要输出多余解释文字”。通过few-shot示例（在提示里给一个小范例输入->输出对），让模型更确信怎么做。这种技巧可应用于推理阶段，确保它不跑题。
- **错误处理**：如果模型在某块生成结果不理想（格式错或内容漏），可以针对这一块**重新微调**或**补充Few-Shot**引导。由于项目标准不高，我们也可简单地多运行几次，或在输出上做规则后处理修正。
- **平衡性能和成本**：本方案在复杂度上进行了平衡——利用一些先进技术（如LoRA微调、Embedding聚类）来满足需求，但不过度追求最优解，以节省时间。很多步骤（如关键句提取、输出校验）我们使用脚本或规则完成，减少对模型推理的依赖，这降低了整体实现难度。
- **通用性**：微调后的模型理想情况下可以应用到18份标准以外的**类似标准**文本。不过由于训练样本少，它更像是专业规则提取器。如果需要扩展到更多标准，应该增补训练数据。当前实现优先满足现有任务需求。

总结

综上所述，我们采用**分而治之**的策略处理长文档，通过**预处理+语义分块**将长文本压缩到模型可处理的片段，再通过**LoRA微调**教会模型输出符合规范的XML结构。推理时逐块生成并拼装，既绕过了上下文长度限制，又保证了每条规则的准确提取。这一方案技术路线清晰，实施难度可控，并能产出直观的结果，满足项目“看起来效果很好”的目标。通过该方案，我们能够在本地算力有限的情况下，高效完成大模型对机械制图技术规范的理解和结构化输出，为后续制图规范检查提供了自动化工具支持。